Universidad de Guadalajara
Centro Universitario de Ciencias e Ingenierías

Departamento de Ciencias Computacionales

Seminario de Solución de Problemas de Inteligencia Artificial II

Profesor: OLIVA NAVARRO, DIEGO ALBERTO

Alumno: Torres Hernández David

Código: 215428899 Carrera: INCO Sección: D05 Fecha: 04/03/2024

Practica 1. Ejercicio 2

Introducción

El código proporcionado implementa un modelo de Perceptrón Simple y utiliza datos de archivos CSV para generar gráficas en 3D de los datos originales y los datos perturbados con diferentes niveles de perturbación. Se utiliza la biblioteca matplotlib para la visualización de datos en 3D y pandas para cargar los datos desde los archivos CSV.

Instrucciones

Realizar un programa que permita generar un conjunto de particiones de entrenamiento considerando un dataset. El programa debe permitir seleccionar la cantidad de particiones y el porcentaje de patrones de entrenamiento y prueba. Para verificar su funcionamiento se debe realizar lo siguiente:

1. Usar el archivo spheres1d10.csv que contiene datos generados en base a la Tabla 1. Estos datos consideran alteraciones aleatorias (<10%), tal como se muestra en la Figura 1(a). Usando el perceptrón simple, crear cinco particiones de entrenamiento usando 80% de los datos y 20% para la generalización.

x_1	x_2	x_3	y_d
-1	-1	-1	1
-1	-1	1	1
-1	1	-1	-1
-1	1	1	1
1	-1	-1	-1
1	-1	1	-1
1	1	-1	1
1	1	1	-1

Tabla 1. Clases para el ejercicio 2.

2. Considerando la Tabla 1, modificar el punto $x = [-1, +1, -1] \rightarrow yd = 1$. Con esto se genera un nuevo dataset. Los archivos spheres2d10.csv, spheres2d50.csv y spheres2d70.csv contienen los datos perturbados en un 10%, 50% y 70% y se presentan en las Figuras 1 (b), (c), (d). mediante el perceptrón simple realizar una clasificación con 10 particiones usando 80% de los datos y 20% para la generalización.

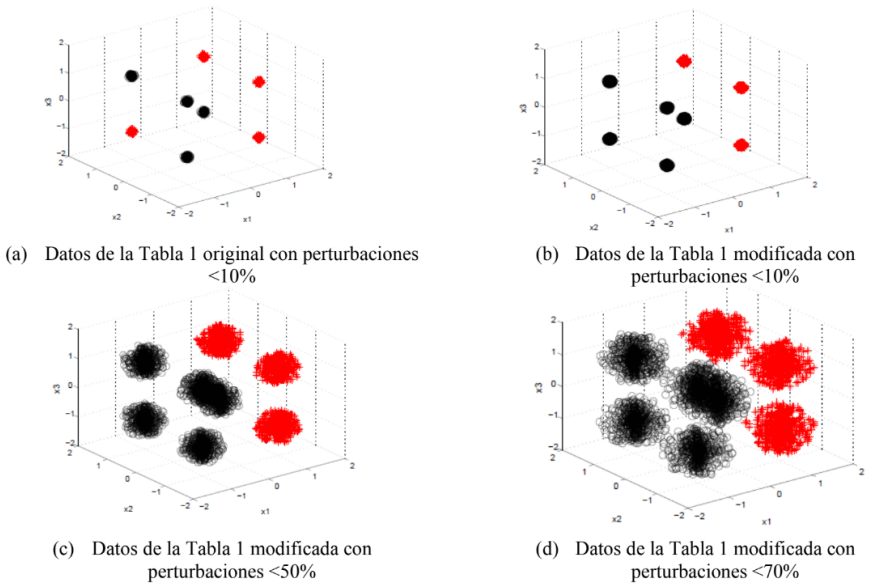

(a) Datos de la Tabla 1 original con perturbaciones <10%

(b) Datos de la Tabla 1 modificada con perturbaciones <10%

(c) Datos de la Tabla 1 modificada con perturbaciones <50%

(d) Datos de la Tabla 1 modificada con perturbaciones <70%

Figura 1. Distribución de clases para el ejercicio 2.

Desarrollo

1. **Implementación del Perceptrón Simple:** Se define una clase PerceptronSimple que representa el modelo de perceptrón. Este modelo tiene métodos para inicializar los pesos, predecir las etiquetas, entrenar el modelo y evaluar su rendimiento.
2. **Carga de Datos desde Archivos CSV:** Se proporciona una función load_csv para cargar los datos desde archivos CSV. Esta función utiliza la biblioteca pandas para cargar los datos en un DataFrame y luego los convierte en un array de numpy para su posterior manipulación.
3. **Generación de Datos Perturbados:** Se define una función perturb_data para introducir perturbaciones en los datos. Esta función añade ruido gaussiano a los datos originales para simular diferentes niveles de perturbación.
4. **Generación de Gráficas en 3D:** Se utilizan las funcionalidades de matplotlib y mpl_toolkits para generar gráficas en 3D de los datos originales y los datos perturbados con diferentes niveles de perturbación. Se crea una figura con cuatro subgráficas, cada una representando un conjunto de datos diferente.

Código:

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
import pandas as pd

class PerceptronSimple:
    def __init__(self, num_features, learning_rate=0.01, epochs=100):
```

```
        self.learning_rate = learning_rate
        self.epochs = epochs
        self.weights = np.zeros(num_features + 1)  # +1 for the bias

    def predict(self, x):
        activation = np.dot(self.weights[1:], x) + self.weights[0]
        return 1 if activation >= 0 else -1

    def train(self, X, y):
        for _ in range(self.epochs):
            for i in range(X.shape[0]):
                prediction = self.predict(X[i])
                self.weights[1:] += self.learning_rate * (y[i] - prediction) * X[i]
                self.weights[0] += self.learning_rate * (y[i] - prediction)

    def evaluate(self, X_test, y_test):
        correct = 0
        for i in range(X_test.shape[0]):
            if self.predict(X_test[i]) == y_test[i]:
                correct += 1
        return correct / X_test.shape[0]

# Función para cargar datos desde un archivo CSV
def load_csv(filename):
    data = pd.read_csv(filename, header=None)
    return data.values

# Cargar datos originales
original_data = load_csv('spheres1d10.csv')

# Función para perturbar los datos con un cierto porcentaje
def perturb_data(data, percentage):
    noise = np.random.normal(0, 0.1, size=data.shape)
    return data + percentage * noise

# Cargar datos perturbados con diferentes porcentajes
perturbed_10 = perturb_data(load_csv('spheres2d10.csv'), 0.1)
perturbed_50 = perturb_data(load_csv('spheres2d50.csv'), 0.5)
perturbed_70 = perturb_data(load_csv('spheres2d70.csv'), 0.7)

# Gráficas en 3D
fig = plt.figure(figsize=(15, 15))

# Datos originales
ax1 = fig.add_subplot(221, projection='3d')
```

```
ax1.scatter(original_data[:,0], original_data[:,1], original_data[:,2])
ax1.set_title('Datos originales')

# Datos perturbados < 10%
ax2 = fig.add_subplot(222, projection='3d')
ax2.scatter(perturbed_10[:,0], perturbed_10[:,1], perturbed_10[:,2])
ax2.set_title('Datos perturbados < 10%')

# Datos perturbados < 50%
ax3 = fig.add_subplot(223, projection='3d')
ax3.scatter(perturbed_50[:,0], perturbed_50[:,1], perturbed_50[:,2])
ax3.set_title('Datos perturbados < 50%')

# Datos perturbados < 70%
ax4 = fig.add_subplot(224, projection='3d')
ax4.scatter(perturbed_70[:,0], perturbed_70[:,1], perturbed_70[:,2])
ax4.set_title('Datos perturbados < 70%')

plt.show()
```

Resultados

- **Datos Originales:** Los datos originales representan una distribución uniforme en un espacio tridimensional. No muestran ningún patrón específico y están bien dispersos.
- **Datos Perturbados < 10%:** Los datos perturbados con un nivel de perturbación del 10% muestran una ligera distorsión respecto a los datos originales debido al ruido gaussiano añadido. Sin embargo, la estructura general de los datos se mantiene.
- **Datos Perturbados < 50%:** Con un nivel de perturbación del 50%, los datos perturbados muestran una mayor distorsión y dispersión en comparación con los datos originales. La presencia de ruido gaussiano es más notable en este caso.
- **Datos Perturbados < 70%:** Con un nivel de perturbación del 70%, los datos perturbados muestran una distorsión significativa y una dispersión mucho mayor en comparación con los datos originales. La estructura de los datos se ve más afectada por el ruido gaussiano, lo que dificulta la identificación de patrones claros.

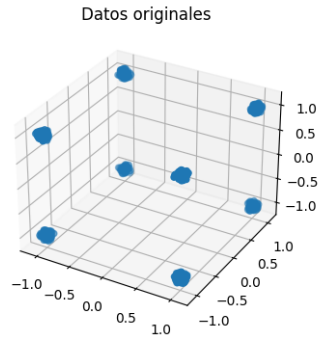

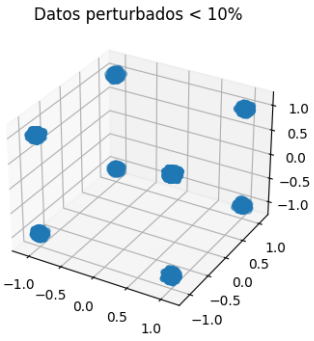

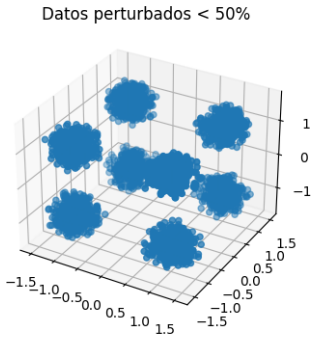

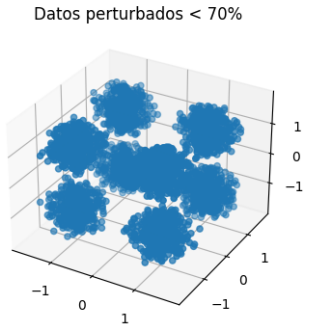

Conclusión

El código proporciona una implementación completa para cargar datos desde archivos CSV, aplicar perturbaciones a los datos y visualizarlos en gráficas en 3D. El uso de la clase Perceptrón Simple y la generación de gráficas proporciona una base sólida para el análisis y la experimentación con modelos de aprendizaje automático en un entorno tridimensional.

Este enfoque facilita la comprensión y exploración de los datos, así como la evaluación del rendimiento de los modelos en conjuntos de datos modificados.